Table 4: R^2 of linear regression models fit using different stratification features. The symbol "*" indicates statistical significance at confidence level $\alpha=0.05$ with respect to the null model, according to the likelihood ratio test.

	TREC robust 2004			TREC DL 2019			TREC DL 2020		
	Mistral 7B	Llama 8E	Qwen 30B	Mistral 7	B Llama 8B	Qwen 30B	Mistral 7B	Llama 8B	Qwen 30B
\overline{A}	0.211 *	0.622 *	0.538 *	0.249 *	0.313 *	0.310 *	0.389 *	0.458 *	0.440 *
ΔP	0.097 *	0.031 *	0.0(0.955)	0.023 *	0.013 *	0.003 *	0.063 *	0.010 *	0.026 *
ΔP_2	0.092 *	0.113 *	0.008 *	0.022 *	0.047 *	0.017 *	0.065 *	0.065 *	0.071 *
P	0.145 *	0.173 *	0.256 *	0.084 *	0.027 *	0.027 *	0.147 *	0.032 *	0.104 *
PPL	0.040 *	0.026 *	0.015 *	0.096 *	0.017 *	$0.028\ ^{\star}$	0.213 *	0.007 *	0.043 *
$\overline{A+P}$	0.238 *	0.634 *	0.569 *	0.253 *	0.331 *	0.311 *	0.390 *	0.474 *	0.450 *
A + PPL	0.225 *	0.623 *	0.541 *	0.250 *	0.313 *	0.311 *	0.390 *	0.458 *	0.440 *
$A + \Delta P$	0.238 *	0.632 *	0.555 *	0.249 *	0.338 *	0.315 *	0.389 *	0.479 *	0.458 *
$A + \Delta P_2$	0.238 *	0.631 *	0.563 *	0.249 *	0.328 *	0.314 *	0.389 *	0.474 *	0.458 *
P + PPL	0.168 *	0.182 *	0.257 *	0.113 *	0.042 *	0.041 *	0.224 *	0.037 *	0.113 *
$P + \Delta P$	0.156 *	0.197 *	0.427 *	0.088 *	0.027 *	0.038 *	0.169 *	0.034 *	0.117 *
$P + \Delta P_2$	0.155 *	0.173 *	0.428 *	0.088 *	0.047 *	0.027 *	0.170 *	0.065 *	0.104 *
$PPL + \Delta P$	0.119 *	0.052 *	0.016 *	0.103 *	0.029 *	0.029 *	0.233 *	0.017 *	0.060 *
$PPL + \Delta P_2$	0.115 *	0.126 *	0.018 *	0.102 *	0.059 *	0.038 *	0.234 *	0.069 *	0.096 *
$\Delta P + \Delta P_2$	0.101 *	0.194 *	0.121 *	0.023 *	0.067 *	0.077 *	0.066 *	0.115 *	0.182 *
A + P + PPL	0.250 *	0.634 *	0.569 *	0.253 *	0.331 *	0.312 *	0.391 *	0.475 *	0.450 *